

Problem Set 03: Forecasting y Pricing

Enero 2026

Información General

Puntaje Total: 140 puntos

Cantidad de Preguntas: 7

Temas: Forecasting (80 pts) + Pricing (60 pts)

Datasets

Pregunta	Dataset
1, 2, 3 (Forecasting)	Store Sales - Time Series Forecasting (Favorita Ecuador)
4 (Forecasting)	M5 Forecasting - Accuracy (Walmart USA)
5 (Pricing)	Online Retail II (UCI - UK E-commerce)
6 (Pricing)	Caso de estudio provisto (sin dataset)
7 (Pricing)	precios_propiedades.xlsx

PARTE I: FORECASTING (80 puntos)

Pregunta 1: Descomposición Temporal e Ingeniería de Variables (20 puntos)

Contexto

Un retailer ecuatoriano desea mejorar su sistema de predicción de demanda. El equipo de data science ha aplicado una descomposición STL a la serie de ventas diarias de la categoría "GROCERY I" y ha obtenido los siguientes componentes: Tendencia (T_t), Estacionalidad (S_t) y Residuo (R_t).

Además, han creado las siguientes variables derivadas para entrenar un modelo de Machine Learning:

```
df['lag_1'] = df['ventas'].shift(1)
df['lag_7'] = df['ventas'].shift(7)
df['rolling_mean_7'] = df['ventas'].rolling(7).mean()
df['dia_semana'] = df['fecha'].dt.dayofweek
df['mes'] = df['fecha'].dt.month
```

Tareas

a) (5 pts) Un analista junior propone utilizar lag_0 (la venta del mismo día) como feature porque "tiene la correlación más alta con el target". Explica por qué esta práctica constituye **Data Leakage** y cuál sería el impacto en las métricas de backtesting vs. la operación real.

b) (5 pts) El componente de Tendencia (T_t) muestra un crecimiento sostenido del 15% anual. Sin embargo, el equipo de finanzas advierte que este crecimiento se debe principalmente a la apertura de nuevas tiendas (factor externo) y no a un aumento orgánico de la demanda por tienda. ¿Cómo afecta esto la interpretación del forecast? Propón una estrategia para aislar la tendencia “real” de demanda.

c) (5 pts) La variable día_semana codificada como entero (0-6) presenta un problema conceptual. Explica por qué la codificación numérica directa es inadecuada para series temporales cíclicas y describe matemáticamente cómo implementar una **codificación cíclica** usando funciones trigonométricas.

d) (5 pts) Al analizar los residuos (R_t), el equipo detecta que los días posteriores a feriados nacionales (como el “Día de los Difuntos”) muestran residuos sistemáticamente positivos de +25%. ¿Qué tipo de variable exógena deberían incorporar y cómo impactaría esto en la decisión de qué modelo utilizar (estadístico vs. ML)?

Pregunta 2: Validación y Métricas de Negocio (20 puntos)

Contexto

El retailer ha implementado tres modelos de forecast para predecir las ventas semanales de 500 SKUs:

Modelo	MAE (unidades)	WAPE (%)	Bias Promedio
Baseline (Naive)	45	18.5%	+2%
LightGBM	32	12.1%	-8%
Prophet	38	14.3%	+1%

El área de Supply Chain indica que: - El costo de **sobre-stock** es \$0.50 por unidad/semana (almacenamiento). - El costo de **quiebre de stock** es \$3.00 por unidad perdida (margen + reputación).

Tareas

a) (6 pts) A pesar de tener el menor WAPE, el modelo LightGBM presenta un Bias de -8%. Interpreta este resultado en términos operacionales: ¿el modelo tiende a sobre-stockear o sub-stockear? Calcula el costo esperado adicional del sesgo si el volumen promedio semanal es de 10,000 unidades.

b) (6 pts) El equipo de ML propone usar validación cruzada K-Fold tradicional (aleatorio) para optimizar hiperparámetros. Explica por qué esta estrategia es **incorrecta** para series temporales y describe con detalle la diferencia entre **Expanding Window** y **Sliding Window**. ¿En qué escenario de retail preferirías cada una?

c) (8 pts) Caso de Ceros Censurados: Al analizar los datos históricos, descubres que 15% de los registros de “ventas = 0” corresponden a días donde el producto estuvo en quiebre de stock (inventario = 0).

- Explica cómo este fenómeno **sesga sistemáticamente** el forecast hacia valores más bajos.
- Propón al menos dos estrategias técnicas para mitigar este problema (una basada en data augmentation y otra en modelado).
- ¿Por qué es este un problema ético además de técnico? Relaciona con la pérdida de ventas atribuible al sistema de forecast.

Pregunta 3: Selección de Algoritmos y Casos Especiales (20 puntos)

Contexto

El retailer tiene un catálogo de 50,000 SKUs con patrones de demanda muy heterogéneos:

Segmento	% del Catálogo	Descripción	Ejemplo
A (Alto volumen)	5%	Ventas diarias, alta rotación	Leche, pan
B (Medio volumen)	25%	Ventas regulares con estacionalidad	Cereales
C (Long Tail)	70%	Demanda intermitente (muchos ceros)	Espicias exóticas

Tareas

a) (7 pts) Para los productos del **segmento C (Long Tail)**, el equipo entrena un modelo ARIMA tradicional pero obtiene predicciones siempre cercanas a la media histórica (aproximadamente 0.3 unidades/día), lo cual es inútil para planificación.

- Explica por qué los modelos continuos (ARIMA, ETS) fallan con **demanda intermitente**.
- Describe el modelo de **Croston** y explica cómo separa el problema en dos componentes: frecuencia de demanda e intensidad cuando ocurre.
- ¿Qué distribución de probabilidad sería más apropiada para modelar la ocurrencia de demanda esporádica?

b) (6 pts) Se propone utilizar **NeuralForecast (NHITS)** para todo el catálogo argumentando que “deep learning siempre es mejor”. Argumenta a favor o en contra de esta posición considerando: - Tamaño de la historia disponible (2 años de datos diarios). - Costo computacional para 50,000 series. - Capacidad de capturar dependencias de muy largo plazo vs. complejidad añadida.

c) (7 pts) Evento Black Friday Ecuador: El equipo necesita generar un forecast para la semana del Black Friday, pero solo tienen 2 observaciones históricas de este evento (años anteriores).

- ¿Por qué los modelos puramente estadísticos (sin regresores) tendrían dificultades extremas para capturar este efecto?
- Propón una estrategia híbrida que combine: (1) un modelo base, (2) variables exógenas categóricas, y (3) ajuste experto de negocio (uplift factor).
- ¿Cómo medirías el éxito del forecast post-evento si no puedes realizar backtesting convencional?

Pregunta 4: Implementación de Forecasting con MLForecast (20 puntos)

Contexto

Usando el dataset **M5 Forecasting - Accuracy** de Kaggle (Walmart USA), debes implementar un pipeline completo de forecasting utilizando la librería **MLForecast** del ecosistema Nixtla.

Dataset: <https://www.kaggle.com/competitions/m5-forecasting-accuracy>

Archivos principales del dataset M5: - `sales_train_evaluation.csv`: Ventas diarias por producto (30,490 series × 1,941 días) - `calendar.csv`: Información de fechas, eventos y SNAP - `sell_prices.csv`: Precios semanales por producto y tienda

Para esta pregunta, trabajarás con un subconjunto de datos: - **Departamento:** “FOODS_3” (mayor volumen dentro de Foods) -

Tiendas: Estado de California (CA_1, CA_2, CA_3, CA_4) - **Periodo de entrenamiento:** d_1 a d_1900 (primeros 1900 días) -

Periodo de test (horizonte): d_1901 a d_1913 (13 días, últimas 2 semanas)

Tareas

a) Preparación de datos (4 pts)

Prepara el dataset en el formato requerido por MLForecast: - Columna `unique_id`: Identificador único por serie (combinación tienda-familia) - Columna `ds`: Fecha en formato datetime - Columna `y`: Variable objetivo (ventas)

Además, crea las siguientes **variables exógenas** (usar `calendar.csv` y `sell_prices.csv`): - `is_event`: Binaria indicando si hay evento especial (columnas `event_name_1`, `event_name_2`) - `snap_CA`: Binaria indicando si es día SNAP en California (programa de asistencia alimentaria) - `sell_price`: Precio de venta del producto (hacer join con `sell_prices.csv`) - `day_of_week`: Día de la semana desde `calendar.csv` (`wday`) - `is_weekend`: Binaria para sábado/domingo

Entregable: Código de preparación y `.head()` del DataFrame resultante.

b) Configuración del pipeline MLForecast (6 pts)

Implementa un pipeline de MLForecast con las siguientes especificaciones:

```
from mlforecast import MLForecast
from mlforecast.lag_transforms import RollingMean, RollingStd
from lightgbm import LGBMRegressor
from xgboost import XGBRegressor
```

1. **Lags:** Incluye lags de 1, 7, 14 y 28 días
2. **Transformaciones de ventana móvil:**
 - Media móvil de 7 y 14 días
 - Desviación estándar móvil de 7 días
3. **Features de fecha:** Día del mes, día del año, semana del año
4. **Modelos:** Entrena al menos 2 modelos (LightGBM y XGBoost)

Entregable: Código completo del pipeline y confirmación de entrenamiento exitoso.

c) Predicción y evaluación (6 pts)

Genera predicciones para el horizonte de 13 días y evalúa el desempeño:

1. Calcula las siguientes métricas **por modelo**:
 - MAE (Mean Absolute Error)
 - RMSE (Root Mean Squared Error)
 - MAPE (Mean Absolute Percentage Error) - *Nota: cuidado con divisiones por cero*
2. Genera una visualización que muestre:
 - Serie histórica (últimos 60 días de entrenamiento)
 - Valores reales del período de test
 - Predicciones de ambos modelos

Entregable: Tabla comparativa de métricas y gráfico de predicciones.

d) Interpretación y decisión de negocio (4 pts)

Basándote en los resultados:

1. ¿Cuál modelo seleccionarías para producción y por qué? Considera no solo las métricas sino también:
 - Tiempo de entrenamiento/inferencia
 - Interpretabilidad (feature importance)
 - Robustez ante outliers
2. Muestra el **feature importance** del modelo ganador. ¿Los features más importantes coinciden con tu intuición de negocio sobre qué factores influyen en las ventas de supermercado?
3. Si el equipo de Supply Chain te pide reducir el sesgo (bias) del forecast, ¿qué ajuste propondrías en el pipeline o en el post-procesamiento?

Entregable: Análisis escrito (máximo 300 palabras) con justificación de decisiones.

PARTE II: PRICING (60 puntos)

Pregunta 5: Estimación de Elasticidad en E-commerce (20 puntos) — IMPLEMENTACIÓN

Contexto

Una empresa de e-commerce del Reino Unido quiere optimizar su estrategia de precios. Utilizarás el dataset **Online Retail II** de Kaggle (originalmente de UCI Machine Learning Repository) para estimar elasticidades de demanda.

Dataset: <https://www.kaggle.com/datasets/mashlyn/online-retail-ii-uci>

Descripción del dataset: - Transacciones de un retailer online UK (2009-2011) - ~1 millón de transacciones - Columnas principales: Invoice, StockCode, Description, Quantity, InvoiceDate, Price, Customer ID, Country

Tareas

a) Preparación de datos para análisis de precios (5 pts)

Filtra y prepara el dataset para análisis de elasticidad:

1. Filtra solo transacciones de UK (Country == 'United Kingdom')
2. Elimina devoluciones (filas con Quantity < 0 o Invoice que empiece con 'C')
3. Elimina registros con Price <= 0 o Customer ID nulo
4. Selecciona los **10 productos más vendidos** (por cantidad total de unidades)
5. Agrega los datos a nivel **producto-semana**: calcula cantidad_total, precio_promedio, n_transacciones

Entregable: Código de preparación y tabla resumen mostrando los 10 productos seleccionados con sus ventas totales.

b) Estimación de elasticidad naive (5 pts)

Para cada uno de los 10 productos, estima la elasticidad precio-demanda usando el modelo Log-Log:

$$\ln(Q_{it}) = \alpha_i + \beta_i \ln(P_{it}) + \epsilon_{it}$$

Donde i es el producto y t es la semana.

1. Implementa la regresión para cada producto usando statsmodels
2. Presenta una tabla con: StockCode, Description, β estimado, p-value, R^2
3. ¿Cuántos productos tienen elasticidad estadísticamente significativa ($p < 0.05$)? ¿Cuántos son elásticos ($|\beta| > 1$) vs. in-elásticos?

Entregable: Código de regresión y tabla de resultados.

c) Modelo con efectos temporales (5 pts)

La estimación naive puede estar sesgada por estacionalidad (ej: Navidad). Implementa un modelo pooled con efectos fijos de tiempo:

$$\ln(Q_{it}) = \beta \ln(P_{it}) + \gamma_i + \delta_t + \epsilon_{it}$$

Donde γ_i son efectos fijos de producto y δ_t son efectos fijos de mes.

1. Usa statsmodels con variables dummy o linearmodels con PanelOLS
2. Compara el $\hat{\beta}$ pooled vs. el promedio de los $\hat{\beta}_i$ individuales

- ¿Por qué la inclusión de efectos temporales podría **cambiar** (aumentar o disminuir) la elasticidad estimada? Relaciona con el concepto de endogeneidad por demanda estacional.

Entregable: Código del modelo panel y comparación de coeficientes.

d) Recomendación de pricing (5 pts)

Supón que el margen de contribución promedio de estos productos es 40% del precio de venta.

- Usando la elasticidad estimada en (c), calcula el **margen de contribución óptimo** según la regla de Lerner: $\frac{P-C}{P} = -\frac{1}{\beta}$
- ¿Sugiere el modelo que la empresa debería **subir o bajar** precios respecto al margen actual del 40%?
- Limitación crítica:** Este dataset no tiene variación exógena de precios (no hay A/B tests ni shocks de costos). ¿Por qué esto limita la interpretación causal de tu elasticidad estimada? Propón una estrategia que la empresa podría implementar para obtener una estimación más robusta.

Entregable: Cálculo del margen óptimo y análisis crítico (máximo 200 palabras).

Pregunta 6: Pricing Dinámico y Discriminación de Precios (20 puntos)

Contexto

RideFlow es una app de transporte similar a Uber que opera en Santiago, Chile. La empresa quiere implementar **pricing dinámico (surge pricing)** y está evaluando estrategias de **discriminación de precios**.

Datos operativos actuales (precio uniforme de \$3,500 CLP por viaje promedio):

Segmento	Descripción	Viajes/día	Elasticidad estimada (β)
Ejecutivos	Viajes L-V 7-9am, zonas empresariales	12,500	-0.6
Casual	Viajes fines de semana, zonas comerciales	17,500	-1.8
Nocturno	Viajes Vie-Sáb 23:00-4:00	10,000	-1.2
Aeropuerto	Viajes hacia/desde SCL	10,000	-0.4

El costo variable promedio por viaje es \$2,100 CLP (combustible, comisión conductor, seguros).

Tareas

a) (4 pts) Análisis de márgenes actuales: 1. Calcula el margen de contribución actual (%) con el precio uniforme de 3,500. 2. Calcula la contribución diaria total con el precio uniforme. 3. Usando la regla de Lerner, calcula el **margen óptimo** para cada segmento. ¿Cuáles están siendo "subexplotados" vs. "sobreexplotados" respecto al óptimo teórico?

b) (6 pts) Diseño de pricing dinámico: 1. Calcula el **precio óptimo** para cada segmento usando

$$P^* = C \cdot \frac{|\beta|}{|\beta| - 1}$$

(derivado de Lerner). 2. Expresa cada precio como un **multiplicador** respecto al precio base de \$3,500. 3. Calcula la **nueva contribución total diaria** si implementaran estos precios óptimos (asumiendo que la cantidad demandada no cambia significativamente en el corto plazo). 4. ¿Cuál es el incremento porcentual en contribución vs. el precio uniforme?

c) (5 pts) Trade-offs y riesgos: 1. El surge pricing genera rechazo en algunos usuarios. Propón una **estrategia de comunicación** para que los usuarios perciban el pricing dinámico como "justo" (ej: transparencia, beneficios al conductor, etc.). 2. ¿Cuál sería un **tope máximo** razonable para el multiplicador de surge? Justifica considerando elasticidad y percepción de justicia. 3. Si los usuarios aprenden a evitar el surge (esperando o usando alternativas), ¿cómo afecta esto la **elasticidad efectiva** del segmento? ¿Subiría o bajaría el precio óptimo?

d) (5 pts) Discriminación de precios y ética: RideFlow está considerando usar machine learning para predecir la **disposición a pagar individual** de cada usuario basándose en: - Historial de viajes (frecuencia, horarios, destinos) - Modelo de celular (proxy de nivel socioeconómico) - Batería restante del celular (urgencia)

1. Desde una perspectiva económica, ¿por qué esta estrategia de **discriminación de precios de primer grado** maximizaría los ingresos teóricos?
2. Identifica al menos **2 problemas éticos** graves con esta estrategia.
3. ¿Existen **restricciones legales** en Chile que podrían prohibir o limitar este tipo de pricing personalizado? Menciona qué normativas podrían aplicar.
4. **Reflexión:** ¿Dónde debería trazar la línea una empresa entre “optimización de precios” y “explotación del consumidor”?

Pregunta 7: Predecir precios (20 puntos)

Contexto

Apliquemos todo lo que hemos aprendido en el Máster y en este curso hasta ahora ;).

Dataset: precios_propiedades.xlsx

Descripción del dataset: - precios_propiedades.xlsx contiene precios de propiedades de Santiago. En la hoja Estudiantes-train-test vienen datos de más de 10 mil propiedades.

Tarea (20 pts)

- Predice el precio de las propiedades de la hoja Estudiantes-target.
- El resultado de tu dataset de predicción debe ser un archivo en formato `xlsx` con solo dos columnas: `titulo_propiedad` y `precio_uf`
- Adicionalmente provee el código de predicción.
- El nombre del archivo debe contener el número del grupo. Por ejemplo: `Grupo_4_PS03Q07.xlsx`
- El grupo que alcance el menor MAPE ganará una invitación (opcional) a comer pizza.

Recomendación

- La data del Censo podría enriquecer enormemente tu dataset.

Instrucciones de entrega

- 1 archivo en `.pdf` con las respuestas para todas las preguntas (en Canvas)
- 1 repo en Github con: (como comentario en la entrega en Canvas)
 - un archivo `.py` por pregunta (asegurar que pueda correr desde consola)
 - un `README.md` que explique el código
 - un archivo de `requirements.txt`
 - el archivo `Grupo_X_PS03Q07.xlsx` en el repo para la pregunta 7

Fin del Problem Set 03